



Isian Substansi Proposal

SKEMA PENELITIAN DASAR (PENELITIAN DASAR FUNDAMENTAL DAN PENELITIAN KERJA SAMA ANTAR PERGURUAN TINGGI)

Pengusul hanya diperkenankan mengisi di tempat yang telah disediakan sesuai dengan petunjuk pengisian dan tidak diperkenankan melakukan modifikasi template atau penghapusan di setiap bagian.

A. JUDUL

Tuliskan judul usulan penelitian maksimal 20 kata

Integrasi Explainable AI Klinis pada Multimodal Deep Learning untuk Deteksi Depresi Berbasis Federated Learning]

B. RINGKASAN

Isian ringkasan penelitian tidak lebih dari 300 kata yang berisi urgensi, tujuan, metode, dan luaran yang ditargetkan

[

Depresi merupakan gangguan kesehatan mental dengan prevalensi yang terus meningkat dan berdampak signifikan terhadap kualitas hidup, produktivitas, serta risiko disabilitas dan bunuh diri, khususnya pada populasi usia produktif dan mahasiswa. Pendekatan skrining dan diagnosis depresi hingga saat ini masih didominasi oleh wawancara klinis dan instrumen self-report, yang rentan terhadap subjektivitas responden dan inkonsistensi interpretasi. Perkembangan kecerdasan buatan (Artificial Intelligence/AI), khususnya deep learning multimodal, menawarkan peluang untuk mendeteksi depresi secara lebih objektif dengan memanfaatkan data teks, audio, dan visual yang mencerminkan indikator verbal maupun non-verbal. Namun demikian, sebagian besar penelitian masih berfokus pada peningkatan performa prediktif model, sementara aspek interpretabilitas klinis, kesiapan operasional, dan pengelolaan data terdistribusi belum terintegrasi secara memadai. Kesenjangan ini membatasi **adopsi sistem AI** dalam **layanan kesehatan mental** yang **menuntut transparansi, kepercayaan, dan akuntabilitas**.

Penelitian ini bertujuan mengembangkan sistem **Federated Multimodal Deep Learning** terintegrasi **Explainable AI (XAI)** untuk deteksi depresi yang efisien dan siap dioperasikan pada lingkungan mobile dengan nama **FED-MIND (Federated Explainable Depression Monitoring Intelligence)**. Pendekatan Federated Learning memungkinkan pelatihan model secara kolaboratif tanpa memusatkan data mentah, sehingga mendukung pemanfaatan sumber data yang heterogen dan terdistribusi. Sistem yang diusulkan menggabungkan modalitas teks, audio, dan visual melalui strategi fusi multimodal, serta dilengkapi mekanisme XAI berbasis SHAP dan LIME untuk menghasilkan penjelasan yang dapat dipahami dan dimanfaatkan oleh tenaga kesehatan sebagai dasar pengambilan keputusan. Metode penelitian meliputi kurasi dan pra-pemrosesan dataset multimodal, pembangunan baseline multimodal terpusat, pengembangan dan pelatihan model federated, evaluasi kinerja menggunakan metrik AUC dan F1-score, serta validasi penjelasan XAI secara konseptual. Luaran yang ditargetkan mencakup model Federated Multimodal Deep Learning terintegrasi XAI yang robust dan dapat dijelaskan secara klinis, prototipe sistem pendukung skrining depresi berbasis mobile, serta publikasi ilmiah pada **jurnal internasional bereputasi Q3**.

]

C. KATA KUNCI

Isian 5 kata kunci yang dipisahkan dengan tanda titik koma (;)

[Deteksi Depresi; *Explainable Artificial Intelligence*; *Federated Learning*; Kesehatan Mental Digital; *Multimodal Deep Learning*]

D. PENDAHULUAN

Pendahuluan penelitian tidak lebih dari 1000 kata yang memuat, latar belakang, rumusan permasalahan yang akan diteliti, pendekatan pemecahan masalah, *state-of-the-art* dan kebaruan, peta jalan (*road map*) penelitian setidaknya 5 tahun. Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan.

Depresi merupakan gangguan kesehatan mental yang memiliki prevalensi tinggi dan dampak signifikan terhadap kualitas hidup, produktivitas, serta risiko disabilitas dan bunuh diri, khususnya pada populasi usia produktif dan mahasiswa. Diperkirakan, pada tahun 2030, depresi akan menjadi penyebab utama disabilitas di dunia, dengan prevalensi yang terus meningkat (1,2). Proses skrining dan diagnosis depresi hingga saat ini masih didominasi oleh pendekatan konvensional berbasis wawancara klinis dan instrumen self-report, yang sangat bergantung pada subjektivitas responden dan interpretasi evaluator. Pendekatan ini berpotensi menimbulkan bias dan inkonsistensi antar penilai, yang mengurangi akurasi dalam diagnosis (1). Hal ini mendorong perlunya pendekatan yang lebih objektif dan dapat diakses secara luas, salah satunya melalui pemanfaatan teknologi digital.

Perkembangan kecerdasan buatan dalam satu dekade terakhir mendorong munculnya pendekatan komputasional untuk deteksi depresi berbasis data perilaku dan komunikasi. Deep learning multimodal, yang mengintegrasikan informasi dari teks, suara, dan visual, terbukti mampu menangkap indikator depresi secara lebih komprehensif dibandingkan pendekatan unimodal. Berbagai penelitian menunjukkan bahwa fusi lintas-modalitas melalui arsitektur CNN-LSTM, Transformer, dan attention mechanism secara konsisten meningkatkan akurasi dan sensitivitas model dalam mendeteksi depresi serta memprediksi tingkat keparahannya (3,4). Model berbasis multimodal ini menggabungkan sinyal non-verbal, seperti dinamika ekspresi wajah dan pola atensi visual, yang dapat memberikan informasi penting yang tidak sepenuhnya tercakup dalam teks (5,6) atau suara saja (7).

Aspek interpretabilitas klinis dan operasionalisasi sistem masih kurang diperhatikan dalam studi terdahulu, karena sebagian besar penelitian hanya memanfaatkan attention atau feature attribution tanpa mengimplementasikannya sebagai **Explainable AI (XAI)** yang dapat dipahami dan digunakan oleh tenaga kesehatan dalam pengambilan keputusan klinis (8,9). Kondisi ini menimbulkan kesenjangan antara kecanggihan teknis model dan kebutuhan layanan kesehatan mental yang menuntut transparansi, kepercayaan, dan akuntabilitas.

Di sisi lain, isu privasi dan regulasi data kesehatan mendorong pemanfaatan **Federated Learning (FL)** sebagai solusi pelatihan terdistribusi tanpa pemusatan data mentah, sehingga menjaga kerahasiaan data dan mengakomodasi heterogenitas sumber data (10,11). Namun, studi FL untuk deteksi depresi umumnya masih terbatas pada modalitas tunggal atau data non-klinis serta belum mengintegrasikan XAI yang relevan secara klinis (12,13). Tantangan tambahan muncul pada penerapan di perangkat mobile, seperti efisiensi komputasi, stabilitas pada data non-IID, dan penyajian penjelasan yang dapat ditindaklanjuti, sehingga tanpa integrasi XAI yang terstandar dan kompatibel dengan arsitektur federated, adopsi sistem AI dalam praktik kesehatan mental akan tetap terbatas (2,14).

Rumusan permasalahan dalam penelitian ini adalah bagaimana merancang arsitektur Federated Multimodal Deep Learning untuk deteksi depresi yang efisien dan aman pada perangkat mobile, serta bagaimana mengintegrasika XAI klinis yang konsisten lintas klien federated dan dapat dipahami oleh tenaga kesehatan. Selain itu, penelitian ini juga bertujuan untuk memastikan keseimbangan antara performa prediktif, privasi data, dan interpretabilitas dalam skenario operasional dunia nyata, sehingga sistem yang dihasilkan dapat diterapkan secara praktis dan diterima dalam praktik klinis kesehatan mental.

Urgensi penelitian ini terletak pada kesenjangan antara kemajuan algoritmik AI untuk deteksi depresi dan keterbatasan penerapannya dalam layanan kesehatan mental digital. Meskipun model AI menunjukkan akurasi yang tinggi, implementasi di dunia nyata masih terhambat oleh rendahnya transparansi, keterbatasan interpretabilitas klinis, serta isu privasi dan keamanan data pasien. Kondisi ini menghambat kepercayaan dan adopsi sistem AI oleh tenaga kesehatan dan institusi. Oleh karena itu, diperlukan pendekatan yang mampu menghasilkan model deteksi depresi yang tidak hanya akurat, tetapi juga dapat dijelaskan secara klinis dan selaras dengan kebutuhan operasional serta regulasi layanan kesehatan mental.

Pendekatan pemecahan masalah dalam penelitian ini difokuskan pada pengembangan **Federated Multimodal Deep Learning** untuk deteksi depresi yang efisien dan aman pada perangkat mobile dengan mengintegrasikan data teks, audio, dan visual guna meningkatkan akurasi deteksi. Pendekatan FL diterapkan untuk memungkinkan pelatihan model secara terdistribusi tanpa pemusatan data, sehingga privasi pengguna tetap terjaga dan kepatuhan terhadap regulasi data dapat dipenuhi (10,15).

Selanjutnya, **XAI** diintegrasikan untuk memastikan hasil deteksi dapat dijelaskan secara klinis dan dipahami oleh tenaga kesehatan. Teknik seperti SHAP dan LIME digunakan untuk mengidentifikasi faktor-faktor kunci yang memengaruhi keputusan model, sehingga meningkatkan transparansi dan kepercayaan dalam penerapan klinis (16). Secara keseluruhan, penelitian ini menekankan **keseimbangan antara performa prediktif, perlindungan privasi, dan interpretabilitas model** dalam skenario operasional dunia nyata, termasuk keterbatasan komputasi dan keamanan pada lingkungan mobile atau edge.

Pemecahan masalah dalam penelitian ini menawarkan **keunggulan inovatif** dibandingkan studi sebelumnya melalui pengembangan Federated Multimodal Deep Learning untuk deteksi depresi berbasis mobile. Pendekatan Federated Learning (FL) memungkinkan pelatihan terdistribusi yang menjaga privasi data dan mengurangi risiko pelanggaran data pribadi, yang menjadi tantangan utama dalam teknologi kesehatan mental digital (10,17). Namun, penerapan FL untuk multimodal deep learning pada deteksi depresi **berbasis mobile masih terbatas** (18), khususnya dalam **integrasi data multimodal** yang tidak hanya mencakup teks (10,19-21). Selain itu, penelitian ini mengintegrasikan XAI untuk menghasilkan penjelasan yang jelas dan dapat dipahami oleh tenaga kesehatan (22-24). Berbeda dari penelitian sebelumnya yang umumnya hanya memanfaatkan attention atau feature attribution tanpa penjelasan klinis yang aplikatif (1,25), penggunaan **SHAP** dan **LIME** dalam studi ini memberikan penjelasan yang lebih terperinci dan mudah diakses, sehingga menjembatani

kesenjangan antara kemajuan algoritmik dan kebutuhan praktis layanan kesehatan mental (16).


Kebaruan penelitian yaitu **integrasi Federated Learning dengan XAI dalam multimodal deep learning untuk deteksi depresi berbasis mobile** (Gambar 1). Penelitian ini menggabungkan data teks, audio, dan visual dalam satu sistem yang dapat dioperasikan pada perangkat mobile, mengatasi tantangan data non-IID dan heterogenitas yang sering dihadapi pada aplikasi Federated Learning di bidang kesehatan mental (10,19). Dengan memanfaatkan temporal features dan non-verbal cues seperti ekspresi wajah dan perhatian visual, penelitian ini berusaha meningkatkan akurasi deteksi depresi, mengingat sinyal non-verbal terbukti lebih informatif daripada hanya mengandalkan teks atau suara (3,7). Pendekatan ini juga mengatasi masalah komputasi dan stabilitas model pada data non-IID, yang menjadi tantangan utama dalam AI berbasis mobile dan edge computing untuk kesehatan mental (10). Dengan demikian, penelitian ini menawarkan kebaruan signifikan, menggabungkan multimodal deep learning, Federated Learning, dan XAI dalam sistem deteksi depresi berbasis mobile yang privasi-preserving, dapat dijelaskan secara klinis, dan siap dioperasikan (2,9).



Gambar 1 State Of The Art

Gambar 2 menyajikan **peta jalan penelitian pengembangan AI untuk deteksi depresi periode 2025-2030**, yang menggambarkan tahapan pencapaian awal, integrasi teknologi federated dan explainable AI, hingga validasi dan implementasi sistem secara berkelanjutan.

Peta Jalan Penelitian: AI untuk Deteksi Depresi (2025-2030)



Gambar 2 Peta Jalan


]

E. METODE

Isian metode atau cara untuk mencapai tujuan yang telah ditetapkan tidak lebih dari 1000 kata. Pada bagian metode wajib dilengkapi dengan diagram alir penelitian yang menggambarkan apa yang sudah dilaksanakan dan yang akan dikerjakan selama waktu yang diusulkan. Format diagram alir dapat berupa file JPG/PNG. Metode penelitian harus memuat sekurang-kurangnya prosedur penelitian, hasil yang diharapkan, indikator capaian yang ditargetkan, serta anggota tim/mitra yang bertanggung jawab pada setiap tahapan penelitian. Metode penelitian harus sejalan dengan Rencana Anggaran Biaya (RAB).

[


Metode Penelitian ini menjelaskan secara sistematis pendekatan yang digunakan untuk mencapai tujuan penelitian dalam pengembangan sistem deteksi depresi berbasis kecerdasan buatan yang aman, multimodal, dan dapat dijelaskan secara klinis. Metodologi penelitian dirancang untuk menjamin keterpaduan antara proses pengolahan data, pemodelan prediktif, evaluasi kinerja, serta integrasi Explainable AI (XAI) dan Federated Learning, sehingga hasil penelitian tidak hanya kuat secara teknis tetapi juga relevan untuk penerapan pada layanan kesehatan mental. Gambar 3 berikut menyajikan kerangka metodologi penelitian yang digunakan, yang disusun dalam beberapa fase utama mulai dari persiapan data hingga validasi akhir sistem.



Gambar 3 Metode Penelitian

Gambar 3 ini menyajikan kerangka metodologi penelitian yang digunakan dalam pengembangan sistem deteksi depresi berbasis kecerdasan buatan yang aman, multimodal, dan dapat dijelaskan, yang disusun secara bertahap mulai dari persiapan data hingga validasi akhir. Metodologi dirancang dalam tiga fase utama, yaitu (1) persiapan dan pengolahan data multimodal (**sudah dilakukan**), (2) pelatihan serta evaluasi model terpusat dan federated, dan (3) integrasi Explainable AI (XAI) klinis serta validasi operasional, sehingga memastikan bahwa sistem yang dihasilkan tidak hanya unggul secara performa prediktif, tetapi juga menjaga privasi data dan dapat dipahami serta diterapkan secara klinis.

Gambar 4 di bawah menggambarkan alur penelitian pengembangan model Federated Multimodal Deep Learning yang terintegrasi dengan Explainable AI (XAI) untuk deteksi depresi. Proses diawali dari sumber data multimodal yang mencakup teks, audio, dan visual, baik yang berasal dari dataset seperti DAIC-WOZ, AVEC maupun data tambahan yang relevan. Setiap modalitas melalui tahap pra-pemrosesan spesifik, di mana teks diproses melalui cleaning, tokenisasi, dan embedding; audio melalui denoising, segmentasi, ekstraksi MFCC, pitch, dan spektrogram; serta video melalui face detection, landmark, analisis ekspresi, dan gaze. Seluruh data kemudian melalui tahap data balancing dan validasi kualitas untuk memastikan konsistensi label dan mengurangi bias sebelum masuk ke skema pelatihan.



Gambar 4 Model Penelitian

Tahap selanjutnya adalah pembentukan data federated, di mana dataset dibagi ke dalam beberapa klien dengan skenario IID dan non-IID untuk mensimulasikan

kondisi dunia nyata yang heterogen. Penelitian membangun baseline multimodal terpusat terlebih dahulu menggunakan encoder teks, audio, dan visual (misalnya BERT dan CNN) dengan skema late fusion serta hyperparameter tuning sebagai benchmark performa. Setelah performa baseline terpenuhi, model dikembangkan ke dalam arsitektur federated menggunakan algoritma FedAvg, yang melibatkan pelatihan lokal di tiap klien, pengiriman parameter, dan agregasi di server pusat tanpa memindahkan data mentah. Evaluasi dilakukan menggunakan metrik AUC, F1-score, dan recall. Pada tahap akhir, Explainable AI diintegrasikan melalui analisis berbasis SHAP (dan analisis temporal) untuk menghasilkan ringkasan penjelasan yang dapat dipahami secara klinis, yang kemudian diuji dari aspek keterbacaan, relevansi, dan konsistensi. Luaran akhir dari proses ini adalah model federated multimodal + XAI yang privasi-preserving, robust terhadap data non-IID, dan siap dioperasikan.

Tabel 1 berikut menyajikan uraian tahapan metode penelitian beserta pembagian tugas tim secara rinci, yang mencakup proses atau kegiatan utama, luaran yang dihasilkan, indikator capaian, serta penanggung jawab pada setiap tahap penelitian. Penyusunan tahapan ini dirancang secara sistematis agar selaras dengan tujuan penelitian, mendukung keterlacakan luaran, serta memastikan keterkaitan yang jelas antara aktivitas penelitian dan Rencana Anggaran Biaya (RAB), sehingga pelaksanaan penelitian dapat berjalan efektif, terukur, dan akuntabel.

Tabel 1 - Uraian Tugas tiap indikator dan Luaran tiap Tahap

Tahap Penelitian	Proses / Kegiatan Utama	Luaran yang Dihasilkan	Indikator Capaian	Penanggung Jawab & Keterkaitan RAB
Tahap 1. Studi Awal & Desain Penelitian	– Melakukan literatur Review - SOTA (multimodal, FL, XAI) – Penyusunan tujuan, ruang lingkup, dan roadmap 2026 – Perumusan aspek etika, privasi, dan kepatuhan riset	Dokumen desain penelitian & protokol etika	Desain metodologi tervalidasi secara teoretis	Ketua Peneliti RAB: honor analisis data, akses jurnal
Tahap 2. Akuisisi Data Multimodal	– Kurasi dataset publik (DAIC-WOZ, AVEC) – Penyiapan data teks, audio, dan visual – Harmonisasi dan verifikasi label depresi	Dataset multimodal terkurasi	Dataset lengkap, terdokumentasi, dan siap diproses	Ketua + Anggota 1+Mahasiswa 1 (asistensi data) RAB: penyimpanan data, komputasi
Tahap 3. Pra-pemrosesan & Validasi Kualitas Data	– Cleaning & embedding teks- Denoising & ekstraksi fitur audio – Face detection & ekstraksi fitur visual – Data balancing & quality control	Dataset multimodal siap pelatihan	Tidak ada data rusak; distribusi kelas terkendali	Anggota 1+Mahasiswa 1 (pra-pemrosesan) RAB: komputasi, perangkat lunak
Tahap 4. Partisi Data Federated	– Simulasi klien federated (kampus/kelas/unit)	Skema dataset federated	Dataset terpartisi valid (IID & non-IID)	Anggota 1+ Anggota 2+Mahasiswa 2

	– Penyusunan skenario IID & non-IID - Kontrol heterogenitas dan imbalance			RAB: komputasi & eksperimen
Tahap 5. Baseline Multimodal Terpusat	– Desain encoder teks, audio, visual - Strategi fusi (late / cross-attention) – Training & hyperparameter tuning	Model baseline terpusat	Nilai AUC/F1 baseline tercapai	Ketua + Anggota 1+ Mahasiswa 1 RAB: GPU/komputasi
Tahap 6. Desain Model Federated Multimodal	– Penentuan algoritma FL (FedAvg) – Penyetelan epoch, learning rate, dan strategi agregasi – - Adaptasi arsitektur multimodal ke skema federated	Arsitektur federated final	Arsitektur siap dilatih	Ketua Peneliti+Anggota 2 (arsitektur & FL) RAB: pengembangan model
Tahap 7. Pelatihan Federated	– Pelatihan lokal tiap klien – Pengiriman parameter & agregasi server – Monitoring konvergensi	Model federated terlatih	Konvergensi stabil & loss menurun	Anggota 1 + Anggota 2+Mahasiswa 2 (monitoring eksperimen) RAB: komputasi & komunikasi
Tahap 8. Evaluasi Kinerja Model	– Evaluasi AUC, F1, recall – Analisis robustness non-IID – Evaluasi overhead komunikasi	Laporan evaluasi kinerja	Kinerja federated $\geq$ ambang target	Ketua + Anggota 1 RAB: analisis data
Tahap 9. Integrasi Explainable AI (XAI)	– Implementasi SHAP/LIME – Analisis feature importance & temporal – Penyusunan ringkasan penjelasan klinis	Modul XAI klinis	Penjelasan dapat dipahami & konsisten	Ketua Peneliti+Anggota 2 (XAI) RAB: pengembangan XAI
Tahap 10. Validasi Klinis & Optimasi Mobile	– Review penjelasan oleh mitra psikolog – Uji keterbacaan & konsistensi – Optimasi model untuk lingkungan mobile/edge	Model siap operasional	Validasi klinis terpenuhi	Pihak External Psikolog + Tim RAB: honor mitra
Tahap 11. Finalisasi & Diseminasi	– Penyusunan artikel ilmiah – Dokumentasi prototipe & repositori – - Penyusunan laporan akhir	Artikel, prototipe, laporan akhir	Artikel tersubmit & luaran tercapai	Ketua Peneliti dan Tim RAB: publikasi & dokumentasi

]

F. HASIL YANG DIHARAPKAN

Jelaskan hasil yang diharapkan atau luaran yang dijanjikan dari penelitian

[
Penelitian ini diharapkan menghasilkan luaran ilmiah dan teknologi yang memberikan kontribusi signifikan bagi pengembangan sistem deteksi depresi berbasis kecerdasan buatan yang privasi-preserving, multimodal, dan dapat dijelaskan secara klinis. Luaran utama penelitian adalah **model Federated Multimodal Deep Learning yang terintegrasi dengan Explainable AI (XAI)** yang dinamakan **FED-MIND (Federated Explainable Depression Monitoring Intelligence)**, yang mampu mendeteksi depresi secara akurat dari berbagai modalitas data (teks, audio, dan visual) tanpa memerlukan pemusatan data mentah, sehingga selaras dengan prinsip perlindungan data kesehatan dan regulasi privasi.

Secara metodologis, penelitian ini diharapkan menghasilkan arsitektur federated yang robust, disertai mekanisme XAI yang konsisten lintas klien dan dapat dipahami oleh tenaga kesehatan. Luaran teknis ini akan diwujudkan dalam bentuk **prototipe sistem** yang dapat dioperasikan pada lingkungan mobile atau edge, serta modul penjelasan klinis yang menyajikan informasi kontribusi fitur dan indikator depresi secara ringkas dan dapat ditindaklanjuti dalam konteks skrining atau layanan konseling.

Selain luaran teknologi, penelitian ini menargetkan luaran akademik berupa artikel ilmiah yang dipublikasikan pada **jurnal internasional bereputasi minimal kuartil Q3 (Scopus-indexed)**. Artikel tersebut akan memuat kontribusi kebaruan pada integrasi Federated Learning, multimodal deep learning, dan Explainable AI dalam domain kesehatan mental. Luaran pendukung lainnya meliputi **dataset terkurasi** (sesuai etika dan izin), dokumentasi metodologi, serta repositori kode sumber untuk mendukung reproduktibilitas dan pengembangan riset lanjutan. Dengan luaran tersebut, penelitian ini diharapkan tidak hanya berdampak pada pengembangan ilmu pengetahuan, tetapi juga berpotensi diadopsi secara institusional dalam ekosistem layanan kesehatan mental digital.

]

G. JADWAL PENELITIAN

Jadwal penelitian disusun berdasarkan pelaksanaan penelitian dan disesuaikan berdasarkan lama tahun pelaksanaan penelitian

[

Tahun ke-1

No	Nama Kegiatan	Bulan											
		1	2	3	4	5	6	7	8	9	10	11	12
1	Studi literatur SOTA & desain penelitian	X	X										
2	Perumusan Kerangka Metodologis dan Desain Eksperimen Penelitian	X	X	X									
3	Akuisisi & kurasi dataset multimodal			X	X								
4	Pra-pemrosesan & validasi kualitas data				X	X							
5	Partisi data federated (IID & non-IID)					X	X						
6	Pengembangan baseline multimodal terpusat						X	X					

7	Desain arsitektur federated multimodal							X	X				
8	Pelatihan model federated								X	X			
9	Evaluasi kinerja & analisis									X	X		
10	Integrasi Explainable AI (XAI) klinis										X	X	
11	Validasi klinis & optimasi mobile										X	X	
12	Penulisan artikel & diseminasi										X	X	X

]

H. DAFTAR PUSTAKA

Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan. Hanya pustaka yang disitasi pada usulan penelitian yang dicantumkan dalam Daftar Pustaka.

- [
1. Ye J, Yu Y, Wang Q, Li W, Liang H, Zheng Y, et al. Multi-modal depression detection based on emotional audio and evaluation text. J Affect Disord [Internet]. 2021 Dec 1;295:904–13. Available from: <https://linkinghub.elsevier.com/retrieve/pii/S0165032721008958>
 2. Leal SS, Ntalampiras S, Sassi R. Speech-Based Depression Assessment: A Comprehensive Survey. IEEE Trans Affect Comput [Internet]. 2025 Jul;16(3):1318–33. Available from: <https://ieeexplore.ieee.org/document/10812871/>
 3. Toto E, Tlachac M, Rundensteiner EA. AudiBERT: A Deep Transfer Learning Multimodal Classification Framework for Depression Screening. In: Proceedings of the 30th ACM International Conference on Information & Knowledge Management [Internet]. New York, NY, USA: ACM; 2021. p. 4145–54. Available from: <https://dl.acm.org/doi/10.1145/3459637.3481895>
 4. Pan Y, Shang Y, Shao Z, Liu T, Guo G, Ding H. Integrating Deep Facial Priors Into Landmarks for Privacy Preserving Multimodal Depression Recognition. IEEE Trans Affect Comput [Internet]. 2024 Jul;15(3):828–36. Available from: <https://ieeexplore.ieee.org/document/10185131/>
 5. Hadzic B, Mohammed P, Danner M, Ohse J, Zhang Y, Shibani Y, et al. Enhancing early depression detection with AI: a comparative use of NLP models. SICE Journal of Control, Measurement, and System Integration [Internet]. 2024 Dec 31;17(1):135–43. Available from: <https://www.tandfonline.com/doi/full/10.1080/18824889.2024.2342624>
 6. Zogan H, Razzak I, Jameel S, Xu G. Hierarchical Convolutional Attention Network for Depression Detection on Social Media and Its Impact During Pandemic. IEEE J Biomed Health Inform [Internet]. 2024 Apr 1;28(4):1815–23. Available from: <https://ieeexplore.ieee.org/document/10041797/>
 7. Hermawan A, Daniawan B, Nathaniel J. Optimization of Multimodal Deep Learning for Depression Detection. IJCCS (Indonesian Journal of Computing and Cybernetics Systems [Internet]. 2025 Oct [cited 2025 Dec 24];19(4):1. Available from: <https://jurnal.ugm.ac.id/ijccs/article/view/111407>
 8. Ahmed U, Lin JCW, Srivastava GS. Hyper-Graph Attention Based Federated Learning Methods for Use in Mental Health Detection. IEEE J Biomed Health Inform [Internet]. 2023 Feb 1;27(2):768–77. Available from: <https://ieeexplore.ieee.org/document/9767700/>
 9. Mimikou C, Kokkotis C, Tsiptsios D, Tsamakis K, Savvidou S, Modig L, et al. Explainable Machine Learning in the Prediction of Depression. Diagnostics [Internet]. 2025 Jun 2;15(11):1412. Available from: <https://www.mdpi.com/2075-4418/15/11/1412>

10. Khalil SS, Tawfik NS, Spruit M. Federated learning for privacy-preserving depression detection with multilingual language models in social media posts. *Patterns* [Internet]. 2024 Jul 12;5(7):100990. Available from: <https://linkinghub.elsevier.com/retrieve/pii/S2666389924001053>
11. Cao X, Zhai L, Zhai P, Li F, He T, He L. Deep learning-based depression recognition through facial expression: A systematic review. Vol. 627, *Neurocomputing*. Elsevier B.V.; 2025.
12. Ducange P, Marcelloni F, Renda A, Ruffini F. Federated Learning of XAI Models in Healthcare: A Case Study on Parkinson's Disease. *Cognit Comput* [Internet]. 2024 Nov 28;16(6):3051–76. Available from: <https://link.springer.com/10.1007/s12559-024-10332-x>
13. Amato A, Branco D. SemFedXAI: A Semantic Framework for Explainable Federated Learning in Healthcare. *Information* [Internet]. 2025 May 25;16(6):435. Available from: <https://www.mdpi.com/2078-2489/16/6/435>
14. Amann J, Blasimme A, Vayena E, Frey D, Madai VI. Explainability for artificial intelligence in healthcare: a multidisciplinary perspective. *BMC Med Inform Decis Mak*. 2020 Dec 1;20(1).
15. Xu J, Glicksberg BS, Su C, Walker P, Bian J, Wang F. Federated Learning for Healthcare Informatics. *J Healthc Inform Res* [Internet]. 2021 Mar 12;5(1):1–19. Available from: <https://link.springer.com/10.1007/s41666-020-00082-4>
16. Ahmed I, Brahmacharimayum A, Ali RH, Khan TA, Ahmad MO. Explainable AI for Depression Detection and Severity Classification From Activity Data: Development and Evaluation Study of an Interpretable Framework. *JMIR Ment Health* [Internet]. 2025 Sep 11;12:e72038–e72038. Available from: <https://mental.jmir.org/2025/1/e72038>
17. Vajrobol V, Singh S, Saxena GJ, Pundir A, Gaurav A, Bansal S, et al. A Comprehensive Survey on Federated Learning Applications in Computational Mental Healthcare. *Computer Modeling in Engineering & Sciences* [Internet]. 2025;142(1):49–90. Available from: <https://www.techscience.com/CMES/v142n1/58982>
18. Opoku Asare K, Terhorst Y, Vega J, Peltonen E, Lagerspetz E, Ferreira D. Predicting Depression From Smartphone Behavioral Markers Using Machine Learning Methods, Hyperparameter Optimization, and Feature Importance Analysis: Exploratory Study. *JMIR Mhealth Uhealth* [Internet]. 2021 Jul 12;9(7):e26540. Available from: <https://mhealth.jmir.org/2021/7/e26540>
19. Gupta C, Khullar V. Modality independent federated multimodal classification system detached EEG, audio and text data for IID and non-IID conditions. *Biomed Signal Process Control* [Internet]. 2025 Oct 1;108:107938. Available from: <https://linkinghub.elsevier.com/retrieve/pii/S1746809425004495>
20. Wang Y, Qu T, Zhu W, Wang Q, Cao Y, Gui R. A hybrid model using multimodal feature perception and multiple cross-attention fusion for depressive episodes detection. *Information Fusion* [Internet]. 2025 Dec 1;124:103354. Available from: <https://linkinghub.elsevier.com/retrieve/pii/S1566253525004270>
21. Yang S, Cui L, Wang L, Wang T, You J. Enhancing multimodal depression diagnosis through representation learning and knowledge transfer. *Heliyon* [Internet]. 2024 Feb 29;10(4):e25959. Available from: <https://linkinghub.elsevier.com/retrieve/pii/S240584402401990X>
22. Uzoma CAE, Agu CP, Chikezie CO, Abi R, Okoronkwo UI. Explainable Hybrid Machine Learning for Mental Health Outcomes: Revealing Latent Patterns in Patient Data. *Journal of Medical Science, Biology, and Chemistry* [Internet]. 2025 Oct 12;2(2):206–16. Available from: <https://journals.stecab.com/jmsbc/article/view/1018>

23. Ahmed MS, Ahmed N. A Fast and Minimal System to Identify Depression Using Smartphones: Explainable Machine Learning–Based Approach. JMIR Form Res [Internet]. 2023 Aug 10;7:e28848. Available from: <https://formative.jmir.org/2023/1/e28848>
24. Hameed S, Nauman M, Akhtar N, Fayyaz MAB, Nawaz R. Explainable AI-driven depression detection from social media using natural language processing and black box machine learning models. Front Artif Intell [Internet]. 2025 Sep 11;8. Available from: <https://www.frontiersin.org/articles/10.3389/frai.2025.1627078/full>
25. Mamidisetti S, A. MR. Multimodal Depression Detection Using Audio, Visual and Textual Cues: A Survey. NeuroQuantology [Internet]. 2022 Apr 22;20(4):325–36. Available from: <https://www.neuroquantology.com/article.php?id=2904>

]